

UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
CIÊNCIA DE DADOS

TRABALHO PRÁTICO DE CIÊNCIA DE DADOS
REGRAS DE ASSOCIAÇÃO APRIORI

Gil Antony Borba
Raphael Muniz Varela
Victor Leal
Ygor Marangoni

Relatório técnico-acadêmico apresentado à disciplina de Ciência de Dados, sob orientação do Prof. Carlos Cesar Mansur Tuma, como parte dos critérios de avaliação.

Monte Carmelo – MG
2026

SUMÁRIO

1 INTRODUÇÃO	1
1.1 Objetivo e escopo	1
1.2 Critérios de sucesso e rastreabilidade	1
2 BASE DE DADOS E PREPARAÇÃO	3
2.1 Origem da amostra	3
2.2 Auditoria dos atributos candidatos	3
2.3 Seleção das oito dimensões	4
2.4 Discretização e justificativa das faixas	5
2.5 Distribuição final das categorias	7
2.6 Zeros semânticos e representação binária	8
3 FUNDAMENTOS E CONFIGURAÇÃO DO APRIORI	9
3.1 Regras de associação e algoritmo Apriori	9
3.2 Suporte, confiança e Lift	9
3.3 Itemsets frequentes e itemsets fechados	9
3.4 Configuração real do WEKA	10
4 ESTRATÉGIA EXPERIMENTAL	11
4.1 Busca do lowerBoundMinSupport	11
4.2 Desafio das regras de exatamente três itens	12
4.3 Execução obrigatória e execução exploratória	12
4.4 Configuração escolhida	12
5 ITEMSETS E CONJUNTO FECHADO	13
5.1 Estrutura dos itemsets frequentes	13
5.2 Processo de fechamento	14
5.3 Regras elegíveis após o fechamento	14
6 RESULTADOS DAS REGRAS DE ASSOCIAÇÃO	15

SUMÁRIO (continuação)

6.1 Top 20 por Lift	15
6.2 Vinte regras, seis padrões de coocorrência	18
6.3 Leitura conjunta de suporte, confiança e Lift	19
7 O QUE FOI NOVIDADE - E O QUE NÃO FOI	21
7.1 Critério de novidade	21
7.2 Novidade preliminar	21
7.3 Padrões interessantes	21
7.4 Regras óbvias, inversões e independência	22
7.5 Síntese interpretativa	22
8 DISCUSSÃO	23
8.1 Implicações analíticas e comerciais	23
8.2 Efeito da discretização e dos parâmetros	23
8.3 Robustez e generalização	23
8.4 Recomendações para validação futura	24
9 LIMITAÇÕES, ÉTICA E USO RESPONSÁVEL	25
9.1 Limitações	25
9.2 Ética, LGPD e governança	25
10 CONCLUSÃO	26
REFERÊNCIAS	27
APÊNDICE A - MAPA DAS DISCRETIZAÇÕES	28
APÊNDICE B - HISTÓRICO COMPLETO DOS TESTES DE SUPORTE	30
APÊNDICE C - TOP 20 COMPLETO E INTERPRETAÇÃO TÉCNICA	32
APÊNDICE D - RASTREABILIDADE DOS ARTEFATOS	34

1 INTRODUÇÃO

A mineração de regras de associação procura identificar combinações de itens que aparecem conjuntamente com frequência em um conjunto de transações. Neste trabalho, essa tarefa foi aplicada a uma amostra real de clientes derivada do projeto de Ciência de Dados desenvolvido ao longo da disciplina. Diferentemente dos trabalhos anteriores, o objetivo não é classificar o cliente nem formar grupos, mas investigar coocorrências entre características demográficas, familiares e financeiras por meio do algoritmo Apriori.

A investigação foi conduzida com ênfase em rastreabilidade. A base utilizada foi preservada sem os pesos da etapa de clusterização, as discretizações foram documentadas, todas as tentativas relevantes de suporte foram registradas e as saídas reais do WEKA foram mantidas no repositório. Essa decisão é particularmente importante porque o enunciado combina requisitos que exigem cuidado técnico: uso de `treatZeroAsMissing=true`, geração de pelo menos trinta regras com três itens, construção do conjunto fechado e seleção final por Lift.

Resultado em uma frase — a mineração encontrou associações apenas moderadas: o maior Lift do conjunto final foi 1,11 e todas as regras selecionadas possuem suporte de 1%. Assim, o principal valor do trabalho está na metodologia auditável e na identificação de hipóteses para investigação, e não em evidências fortes para tomada de decisão.

1.1 Objetivo e escopo

O objetivo geral foi executar Regras de Associação Apriori no conjunto de dados do trabalho anterior, sem os pesos, realizando as discretizações necessárias, determinando o menor suporte operacional capaz de produzir ao menos trinta regras de exatamente três itens e, por fim, analisando as vinte regras elegíveis mais bem posicionadas por Lift.

O escopo foi deliberadamente descritivo. TARGET não foi utilizado como item, SK_ID_CURR e ROW_ID_AMOSTRA foram excluídos da mineração e nenhuma regra foi interpretada como relação causal. As associações são válidas apenas no contexto da amostra, das faixas discretizadas e da configuração adotada.

1.2 Critérios de sucesso e rastreabilidade

Foram considerados critérios de sucesso: (a) uso de uma base sem pesos e sem identificadores; (b) oito dimensões conceituais discretizadas em categorias interpretáveis; (c) representação técnica compatível com `treatZeroAsMissing=true`; (d) execução real do Apriori

no WEKA 3.8.7; (e) preservação dos itemsets e geração do conjunto fechado; (f) existência de pelo menos trinta regras de três itens em execução auditável; e (g) seleção das vinte melhores regras por Lift, com interpretação explícita do que é interessante, novidade preliminar ou apenas reformulação de um mesmo padrão.

Tabela 1 — Síntese dos requisitos e da evidência preservada

Requisito	Status	Evidência
Base do trabalho anterior sem pesos	Atendido	10.000 registros da amostra analítica do Trabalho 3, antes da ponderação.
8 dimensões discretizadas	Atendido	27 categorias nominais com frequências validadas.
treatZeroAsMissing=true	Atendido	Representação one-hot {0,1}; zero é ausência do item.
numRules=30 e outputItemSets=true	Atendido	Execução final preservada com -N 30, -I e -Z.
≥30 regras de 3 itens	Atendido com estratégia exploratória	N=2000, suporte 1%, 1.504 regras, 36 com exatamente 3 itens.
Conjunto fechado	Atendido	5.072 fechados; 47 itemsets redundantes removidos.
Top 20 por Lift	Atendido	20 regras escolhidas dentre 36 regras de três itens fechadas.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

2 BASE DE DADOS E PREPARAÇÃO

2.1 Origem da amostra

A base utilizada no Trabalho 4 é a amostra analítica de 10.000 registros produzida no Trabalho 3. Essa escolha atende literalmente ao requisito de usar o conjunto de dados do trabalho anterior “sem os pesos”, pois a amostra preserva os valores anteriores à normalização Min-Max e à multiplicação por raiz dos pesos aplicadas na clusterização. A base ponderada do Trabalho 3 não foi usada como entrada do Apriori.

Tabela 2 — Características das bases utilizadas na preparação

Artefato	Dimensão	Papel no pipeline
Amostra analítica de origem	10.000	Valores originais; preserva identificadores apenas para rastreabilidade.
Base discretizada	10.000×8	Oito dimensões nominais, sem TARGET e sem identificadores.
Base binária	10.000×27	Vinte e sete itens {0,1}; exatamente oito itens ativos por transação.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

A auditoria local da base discretizada confirmou 10.000 linhas. 8 atributos. ausência de valores nulos e 27 categorias no total. A base binária também possui 10.000 linhas. 27 itens. apenas valores 0 e 1 e soma exatamente igual a 8 em todas as linhas. Registros com a mesma combinação de categorias podem naturalmente se repetir; isso representa transações com perfis idênticos. e não duplicação acidental do processo.

2.2 Auditoria dos atributos candidatos

Antes da discretização foram avaliados treze candidatos. A análise considerou tipo, mínimo, máximo, média, mediana, quantis, frequência de zeros, assimetria, possíveis outliers e concentração da categoria dominante. O objetivo não foi escolher variáveis “mais preditivas”, mas obter dimensões diferentes o bastante para produzir regras interpretáveis e reduzir relações triviais ou redundantes.

Tabela 3 — Auditoria e decisão sobre os 13 atributos candidatos

Atributo	Decisão	Evidência resumida	Justificativa
Crédito	Incluído	zeros 0.00%; assimetria 1.27; dominante 3.52%	Representa diretamente o porte do crédito e possui distribuição adequada à discretização por quartis.
Renda total	Incluído	zeros 0.00%; assimetria 99.02; dominante 11.48%	Dimensão econômica central; a discretização por quartis reduz o impacto do máximo extremo de R\$ 117 milhões.
Idade	Incluído	zeros 0.00%; assimetria 0.12; dominante 0.11%	Representa estágio de vida, com distribuição equilibrada e baixa assimetria.
Filhos	Incluído	zeros 69.61%; assimetria 1.72; dominante 69.61%	Acrescenta composição familiar; o zero é informação real e foi rotulado como “sem filhos”.
Posse de carro	Incluído	zeros 66.05%; dominante 66.05%	Dimensão patrimonial simples e interpretável; os códigos 0/1 foram recuperados como rótulos nominais.
Situação familiar	Incluído	zeros 0.01%; dominante 63.44%	Complementa o perfil familiar; os códigos foram reconvertidos por dicionário e categorias raras foram agrupadas.
Créditos ativos	Incluído	zeros 29.56%; assimetria 1.47; dominante 29.56%	Resume intensidade do histórico externo de crédito e preserva o zero semântico.
Taxa de rejeição prévia	Incluído	zeros 67.71%; assimetria 1.81; dominante 67.71%	Introduz histórico de rejeição em dimensão distinta de renda e crédito; 67,71% de zeros foram tratados semanticamente.
Razão crédito/renda	Excluído	zeros 0.00%; assimetria 1.71; dominante 1.61%	É derivado matematicamente de crédito e renda; poderia gerar associações tautológicas.
Rating regional	Excluído	zeros 0.00%; dominante 74.16%	Baixa granularidade: três níveis e 74,16% na categoria dominante.
Qtde. empréstimos Serasa	Excluído	zeros 13.86%; assimetria 1.62; dominante 13.86%	Sobreposição com créditos ativos; a correlação de Spearman registrada foi 0,7657.
Qtde. tentativas anteriores	Excluído	zeros 5.55%; assimetria 2.41; dominante 17.48%	Sobreposição com a taxa de rejeição; correlação de Spearman registrada de 0,5488.
Dívida atrasada Serasa	Excluído	zeros 98.80%; assimetria 59.77; dominante 98.80%	Extrema concentração em zero (98,80%), com alto risco de regras frequentes porém pouco informativas.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

Dois descartes merecem destaque. CREDIT_INCOME_RATIO foi removido porque é uma função de AMT_CREDIT e AMT_INCOME_TOTAL; sua presença poderia transformar

relações matemáticas previsíveis em “descobertas” artificiais. SER_DIVIDA_ATRASADA, por sua vez, apresentou 98,80% de zeros, concentração que favoreceria regras frequentes dominadas pela ausência de dívida e pouco informativas sobre perfis minoritários.

2.3 Seleção das oito dimensões

A seleção final reúne quatro dimensões econômicas ou de histórico de crédito e quatro dimensões demográficas/familiares. Essa combinação foi escolhida para ampliar a diversidade das regras sem aumentar excessivamente o espaço de busca.

Tabela 4 — Oito dimensões conceituais selecionadas

Dimensão	Campo original	Representação final
Crédito	AMT_CREDIT	Crédito baixo, Crédito alto, Crédito muito alto, Crédito médio
Renda	AMT_INCOME_TOTAL	Renda baixa, Renda alta, Renda muito alta, Renda média
Idade	AGE_YEARS	Idade entre 30 e 39 anos, Idade entre 40 e 49 anos, Idade entre 50 e 59 anos, Idade de 60 anos ou mais, Idade entre 21 e 29 anos
Filhos	CNT_CHILDREN	Sem filhos, Um filho, Dois ou mais filhos
Posse de carro	FLAG_OWN_CAR_COD	Sem carro, Com carro
Situação familiar	NAME_FAMILY_STATUS_COD	Casado ou em união civil, Solteiro, Separado, viúvo ou não informado
Créditos ativos	SER_CREDITOS_ATIVOS	Um a dois créditos ativos, Sem créditos ativos, Três ou mais créditos ativos
Rejeição prévia	PREV_TAXA_REJEICAO	Sem rejeição prévia, Taxa de rejeição prévia acima de 25%, Taxa de rejeição prévia até 25%

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

2.4 Discretização e justificativa das faixas

A discretização não utilizou intervalos de mesma largura. Crédito e renda foram divididos por quartis reais, reduzindo a influência das caudas e dos outliers. A idade foi organizada em faixas semânticas de ciclo de vida. Contagens e proporções receberam cortes que preservam o significado do zero e evitam categorias muito pequenas. Os códigos de carro e estado familiar foram reconvertidos para rótulos nominais por meio do dicionário produzido no Trabalho 1.

Tabela 5 — Discretização de AMT_CREDIT

Categoria	Regra de corte	Critério	n	%
Crédito baixo	Até R\$ 270.000	P25	2.555	25,55%
Crédito médio	R\$ 270.000 < crédito ≤ R\$ 512.721	P25 a P50	2.445	24,45%

Categoria	Regra de corte	Critério	n	%
Crédito alto	R\$ 512.721 < crédito ≤ R\$ 810.000	P50 a P75	2.518	25,18%
Crédito muito alto	Acima de R\$ 810.000	Acima de P75	2.482	24,82%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 6 — Discretização de AMT_INCOME_TOTAL

Categoria	Regra de corte	Critério	n	%
Renda baixa	Até R\$ 112.500	P25	3.279	32,79%
Renda média	R\$ 112.500 < renda ≤ R\$ 148.500	P25 a P50	1.739	17,39%
Renda alta	R\$ 148.500 < renda ≤ R\$ 202.500	P50 a P75	2.588	25,88%
Renda muito alta	Acima de R\$ 202.500	Acima de P75	2.394	23,94%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 7 — Discretização de AGE_YEARS

Categoria	Regra de corte	Critério	n	%
Idade entre 21 e 29 anos	21 a 29 anos	Semântico	1.218	12,18%
Idade entre 30 e 39 anos	30 a 39 anos	Semântico	2.660	26,60%
Idade entre 40 e 49 anos	40 a 49 anos	Semântico	2.526	25,26%
Idade entre 50 e 59 anos	50 a 59 anos	Semântico	2.178	21,78%
Idade de 60 anos ou mais	60 anos ou mais	Semântico	1.418	14,18%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 8 — Discretização de CNT_CHILDREN

Categoria	Regra de corte	Critério	n	%
Sem filhos	0 filhos	Zero semântico	6.961	69,61%
Um filho	1 filho	Semântico	2.005	20,05%
Dois ou mais filhos	2 ou mais filhos	Frequência	1.034	10,34%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 9 — Discretização de FLAG_OWN_CAR_COD

Categoria	Regra de corte	Critério	n	%
Sem carro	Código 0 → sem carro	Dicionário do Trabalho 1	6.605	66,05%
Com carro	Código 1 → com carro	Dicionário do Trabalho 1	3.395	33,95%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 10 — Discretização de NAME_FAMILY_STATUS_COD

Categoria	Regra de corte	Critério	n	%
Casado ou em união civil	Códigos 1 ou 2	Semântica e frequência	7.304	73,04%
Solteiro	Código 4	Dicionário do Trabalho 1	1.498	14,98%
Separado, viúvo ou não informado	Códigos 0, 3 ou 5	Frequência	1.198	11,98%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 11 — Discretização de SER_CREDITOS_ATIVOS

Categoria	Regra de corte	Critério	n	%
Sem créditos ativos	0 créditos ativos	Zero semântico	2.956	29,56%
Um a dois créditos ativos	1 a 2 créditos ativos	Frequência	4.346	43,46%
Três ou mais créditos ativos	3 ou mais créditos ativos	Frequência	2.698	26,98%

Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

Tabela 12 — Discretização de PREV_TAXA_REJEICAO

Categoria	Regra de corte	Critério	n	%
Sem rejeição prévia	Taxa = 0%	Zero semântico	6.771	67,71%
Taxa de rejeição prévia até 25%	$0\% < \text{taxa} \leq 25\%$	P25 entre valores positivos	1.527	15,27%
Taxa de rejeição prévia acima de 25%	Taxa > 25%	P50 aproximado entre valores positivos	1.702	17,02%


Fonte: elaboração própria a partir de proposta_faixas.csv e frequencias_finais.csv.

2.5 Distribuição final das categorias

A discretização produziu 27 categorias. Nenhuma ficou abaixo de 10,34% da amostra, o que reduz o risco de criar regras apoiadas em categorias extremamente raras. As maiores concentrações ocorreram em casado/união civil (73,04%), sem filhos (69,61%), sem rejeição

prévia (67,71%) e sem carro (66,05%). Essas frequências marginais são essenciais para interpretar confiança e Lift posteriormente.

Figura 1 — Frequências das 27 categorias após a discretização



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

2.6 Zeros semânticos e representação binária

Durante a auditoria do WEKA 3.8.7 foi identificado um problema crítico: a opção -Z (treatZeroAsMissing=true) trata o primeiro valor nominal de cada atributo como ausente. Na base nominal multivalorada, o primeiro valor era uma categoria real; portanto, executar Apriori diretamente nesse ARFF descartaria informação válida e alteraria os suportes.

A solução adotada foi uma representação transacional one-hot. Cada uma das 27 categorias passou a ser um item binário independente declarado como {0,1}; o valor 0 aparece primeiro e significa ausência do item, enquanto 1 significa presença. Como cada cliente pertence exatamente a uma categoria de cada uma das oito dimensões conceituais, toda

transação possui exatamente oito valores iguais a 1. Essa transformação é técnica: não cria 27 “novas características”, mas representa as categorias das oito dimensões no formato adequado à mineração de itens.

Validação crítica — a base binária tem 10.000 transações e 27 itens; o número mínimo, máximo e médio de itens ativos por transação é 8, 8 e 8, respectivamente. Nenhum valor ausente foi encontrado.

Tabela 13 — Validações da representação binária utilizada no Apriori

Verificação	Resultado	Interpretação
Registros	10.000	Mesma quantidade da base discretizada.
Itens binários	27	Uma coluna para cada categoria discretizada.
Domínio dos valores	{0,1}	0 = item ausente; 1 = item presente.
Itens ativos por transação	8 em todas as linhas	Exatamente uma categoria ativa por dimensão conceitual.
Valores ausentes	0	Nenhum marcador nulo ou categoria perdida.
Paridade de frequências	Exata	A soma de cada coluna binária coincide com a frequência da categoria nominal correspondente.

Fonte: auditoria programática de base_apriori_discretizada.csv, base_apriori_binaria.csv e frequencias_finais.csv.

Perfis categóricos idênticos podem ocorrer em diversos clientes e são legítimos: cada linha continua sendo uma transação independente. A codificação binária apenas altera a representação dos itens e não duplica registros nem muda as faixas aprovadas.

3 FUNDAMENTOS E CONFIGURAÇÃO DO APRIORI

3.1 Regras de associação e algoritmo Apriori

Uma regra de associação possui a forma $X \rightarrow Y$, em que X é o antecedente e Y o consequente. O algoritmo Apriori explora a propriedade antimonotônica do suporte: se um conjunto de itens não é frequente, qualquer superconjunto que o contenha também não será frequente. Com isso, o espaço de busca é podado antes da geração das regras.

Neste trabalho, cada transação representa um cliente e cada item corresponde a uma categoria discretizada, por exemplo “renda alta”, “solteiro” ou “um a dois créditos ativos”. A regra descreve coocorrência, não causalidade. Uma direção $X \rightarrow Y$ também não significa que X anteceda Y temporalmente.

3.2 Suporte, confiança e Lift

As três métricas foram interpretadas conjuntamente. O suporte mede a parcela de transações contendo todos os itens da regra; a confiança mede, entre os registros que contêm o antecedente, a parcela que também contém o consequente; e o Lift compara essa confiança com a frequência basal do consequente.

$$\text{suporte}(X \rightarrow Y) = \text{suporte}(X \cup Y)$$

$$\text{confiança}(X \rightarrow Y) = \text{suporte}(X \cup Y) / \text{suporte}(X)$$

$$\text{Lift}(X \rightarrow Y) = \text{confiança}(X \rightarrow Y) / \text{suporte}(Y)$$

A leitura do Lift é particularmente importante neste conjunto. Valores próximos de 1 indicam comportamento próximo da independência; valores acima de 1 apontam associação positiva e valores abaixo de 1 indicam associação negativa. Uma confiança aparentemente alta pode ser enganosa quando o consequente já é muito frequente na amostra.

3.3 Itemsets frequentes e itemsets fechados

Itemset é um conjunto de itens observado em uma ou mais transações. Após a mineração, foi construído o conjunto fechado. Um itemset X é fechado quando não existe superconjunto próprio Y contendo X com exatamente o mesmo suporte. O fechamento elimina representações redundantes sem perder a informação de suporte associada ao padrão.

3.4 Configuração real do WEKA

Tabela 14 — Configuração final preservada do Apriori

Parâmetro	Valor
WEKA	3.8.7
Java	OpenJDK Temurin 17.0.20
Algoritmo	weka.associations.Apriori
numRules	30
Métrica	Lift (-T 1)
Pontuação mínima	0,00 (-C 0.00)
lowerBoundMinSupport	0,01
upperBoundMinSupport	0,01
delta	0,01
outputItemSets	true (-I)
treatZeroAsMissing	true (-Z)
Tempo WEKA da execução final	4,22 s

Fonte: *configuracao_apriori_final.json* preservado no repositório.

A execução final gerou 30 regras e 5.119 itemsets. Entretanto, as trinta regras retornadas pelo ranking configurado possuem cinco ou seis itens, e não três. Essa limitação motivou uma execução exploratória separada, descrita no capítulo seguinte, sem substituir nem editar a saída obrigatória $N=30$.

4 ESTRATÉGIA EXPERIMENTAL

4.1 Busca do lowerBoundMinSupport


A busca do suporte foi realizada de forma incremental e auditável. Inicialmente, manteve-se a métrica de confiança padrão e foram testados suportes de 50% até 1%, incluindo janelas curtas e valores exatos. Com confiança mínima de 0,90, os testes não produziram trinta regras de exatamente três itens. Em seguida, com autorização metodológica, foram avaliadas Lift, leverage e conviction e diferentes limites mínimos de métrica.

Tabela 15 — Pontos de decisão na busca do suporte

Teste	Suporte	N	Métrica	Regras	3 itens	Itemsets
suporte_050	0,500	30	confidence (0)	0	0	0
suporte_020	0,200	30	confidence (0)	1	0	54
suporte_010	0,100	30	confidence (0)	7	4	221
suporte_005	0,050	30	confidence (0)	9	4	652
suporte_002 (expl.)_n200	0,020	200	confidence (0)	107	13	2358
lift_c010_s002 (expl.)_n500	0,020	500	lift (1)	152	24	2358
lift_c000_s002 (expl.)_n500	0,020	500	lift (1)	152	24	2358
lift_c000_s001 (expl.)_n2000	0,010	2000	lift (1)	1504	36	5119
lift_c000_s001_n30	0,010	30	lift (1)	30	0	5119

Fonte: resumo_testes_suporte.csv; tabela completa no Apêndice B.

Figura 2 — Relação entre suporte mínimo e quantidade de regras com três itens



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

4.2 Desafio das regras de exatamente três itens

O WEKA 3.8.7 não oferece um parâmetro nativo para limitar o tamanho total da regra a três itens. Para este trabalho, “três itens” foi definido como a soma da quantidade de itens no antecedente e no consequente. Assim, uma regra com dois itens à esquerda e um à direita, ou um à esquerda e dois à direita, possui total igual a três.

A execução obrigatória N=30 não atendeu a esse critério, porque o ranking por Lift priorizou regras mais longas. Em vez de alterar ou truncar a saída, foi preservada uma segunda execução exploratória com N=2000. Essa execução retornou 1.504 regras no total, das quais 36 possuem exatamente três itens. A separação entre “execução obrigatória” e “execução exploratória para filtragem de tamanho” é mantida em todo o relatório.

4.3 Execução obrigatória e execução exploratória

Tabela 16 — Diferença entre as duas execuções centrais do trabalho

Execução	N	Suporte	Métrica	Regras	3 itens	Tamanho	Finalidade
Obrigatória	30	0,01	Lift	30	0	5 ou 6 itens	Comprova -N 30, -I e -Z e preserva a saída exigida.
Exploratória	2.000	0,01	Lift	1.504	36	Filtro posterior = 3 itens	Permite localizar ≥ 30 regras de 3 itens sem falsificar a execução N=30.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

4.4 Configuração escolhida

O suporte efetivo de 1% foi mantido porque foi a primeira configuração auditada capaz de fornecer pelo menos trinta regras com três itens: 36 regras elegíveis. Em uma amostra de 10.000 transações, suporte de 1% corresponde a 100 clientes. Esse valor atende ao requisito, mas é baixo o bastante para exigir cautela na interpretação; por isso o suporte aparece explicitamente em todas as conclusões sobre os padrões finais.

5 ITEMSETS E CONJUNTO FECHADO


5.1 Estrutura dos itemsets frequentes

Tabela 17 — Itemsets frequentes por tamanho

Nível	Quantidade
L(1)	27
L(2)	309
L(3)	1.405
L(4)	2.103
L(5)	1.093
L(6)	176
L(7)	6
Total	5.119

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

Figura 3 — Quantidade de itemsets por tamanho e condição de fechamento



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

O maior volume aparece em L(4), com 2.103 itemsets, seguido de L(3), com 1.405. A presença de itemsets até tamanho sete mostra que as categorias discretizadas geraram ampla combinação de coocorrências; contudo, quantidade não equivale a relevância. A etapa de fechamento e o filtro de tamanho são necessários para reduzir redundância antes da interpretação.

5.2 Processo de fechamento

Dos 5.119 itemsets frequentes, 5.072 foram classificados como fechados e 47 foram removidos por possuírem superconjunto de mesmo suporte. Em termos percentuais, 99.08% dos itemsets permaneceram. Os 47 não fechados concentraram-se entre tamanhos três e seis; nenhum itemset de tamanho um, dois ou sete foi removido.

Tabela 18 — Fechamento dos itemsets por tamanho

Tamanho	Total	Fechados	Removidos	% mantido
1	27	27	0	100,00%
2	309	309	0	100,00%
3	1405	1394	11	99,22%
4	2103	2080	23	98,91%
5	1093	1082	11	98,99%
6	176	174	2	98,86%
7	6	6	0	100,00%

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

5.3 Regras elegíveis após o fechamento


As 36 regras de exatamente três itens permaneceram associadas a itemsets fechados. Esse resultado é importante porque garante que a seleção do Top 20 não depende de conjuntos redundantes removidos pelo fechamento. A ordenação final foi então realizada exclusivamente entre regras de três itens, fechadas, com métricas válidas.

6 RESULTADOS DAS REGRAS DE ASSOCIAÇÃO

6.1 Top 20 por Lift

As vinte regras finais foram ordenadas por Lift decrescente, com suporte e confiança como critérios de desempate. Todas possuem suporte de 1%, isto é, representam 100 transações. O maior Lift é 1,11 e o menor Lift ainda presente no Top 20 é 0,95. A inclusão de regras com Lift abaixo de 1 não foi um erro de seleção: elas permanecem porque o enunciado solicita vinte regras e existem apenas 36 candidatas de três itens; o ranking é apresentado sem ocultar associações neutras ou negativas.

Figura 4 — Top 20 regras de três itens por Lift



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

6.1.1 Tabela consolidada das vinte regras

As tabelas a seguir preservam as métricas reais do ranking e traduzem os itens técnicos para linguagem natural. A orientação paisagem foi utilizada exclusivamente para evitar colunas comprimidas e quebras artificiais de palavras.

Tabela 19 — Top 20 por Lift — regras R1 a R10

Regra	Descrição em linguagem natural	Sup.	Conf.	Lift	Classe
R1	Idade de 60 anos ou mais + um a dois créditos ativos → taxa de rejeição prévia até 25%	1,0%	17%	1,11	Interessante
R2	Taxa de rejeição prévia até 25% → idade de 60 anos ou mais + um a dois créditos ativos	1,0%	7%	1,11	Óbvvia
R3	Crédito muito alto + separado, viúvo ou não informado → um a dois créditos ativos	1,0%	48%	1,10	Novidade
R4	Renda alta + solteiro → crédito médio	1,0%	27%	1,10	Interessante
R5	Um a dois créditos ativos + taxa de rejeição prévia até 25% → idade de 60 anos ou mais	1,0%	16%	1,10	Óbvvia
R6	Idade de 60 anos ou mais → um a dois créditos ativos + taxa de rejeição prévia até 25%	1,0%	7%	1,10	Óbvvia
R7	Crédito médio → renda alta + solteiro	1,0%	4%	1,10	Óbvvia
R8	Um a dois créditos ativos → crédito muito alto + separado, viúvo ou não informado	1,0%	2%	1,10	Óbvvia
R9	Idade entre 30 e 39 anos + taxa de rejeição prévia até 25% → renda muito alta	1,0%	26%	1,07	Interessante
R10	Renda muito alta → idade entre 30 e 39 anos + taxa de rejeição prévia até 25%	1,0%	4%	1,07	Óbvvia

Fonte: top20_regras_lift.csv e analise_top20_regras.csv.

Tabela 20 — Top 20 por Lift — regras R11 a R20


Regra	Descrição em linguagem natural	Sup.	Conf.	Lift	Classe
R11	Crédito médio + renda alta → solteiro	1,0%	16%	1,05	Óbvia
R12	Solteiro → crédito médio + renda alta	1,0%	7%	1,05	Óbvia
R13	Com carro + solteiro → crédito médio	1,0%	24%	0,99	Óbvia
R14	Crédito médio → com carro + solteiro	1,0%	4%	0,99	Óbvia
R15	Idade entre 21 e 29 anos + taxa de rejeição prévia até 25% → casado ou em união civil	1,0%	71%	0,98	Óbvia
R16	Casado ou em união civil → idade entre 21 e 29 anos + taxa de rejeição prévia até 25%	1,0%	1%	0,98	Óbvia
R17	Crédito médio + solteiro → renda alta	1,0%	25%	0,97	Óbvia
R18	Renda alta → crédito médio + solteiro	1,0%	4%	0,97	Óbvia
R19	Renda muito alta + idade entre 30 e 39 anos → taxa de rejeição prévia até 25%	1,0%	15%	0,95	Óbvia
R20	Taxa de rejeição prévia até 25% → renda muito alta + idade entre 30 e 39 anos	1,0%	7%	0,95	Óbvia

Fonte: top20_regras_lift.csv e analise_top20_regras.csv.

6.2 Vinte regras, seis padrões de coocorrência

A reanálise do conjunto completo de 36 regras de três itens revela um resultado que não estava suficientemente destacado na versão anterior do relatório: as 36 regras correspondem a apenas seis itemsets distintos de três itens. Cada itemset de três itens pode gerar seis direções diferentes de regra; portanto, grande parte do Top 20 é composta por inversões ou repartições do mesmo coocorrimento. Em outras palavras, o trabalho não encontrou vinte fenômenos independentes, e sim seis padrões básicos apresentados em diferentes direções.

Figura 5 — Seis padrões únicos subjacentes às 36 regras de três itens



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

Tabela 21 — Síntese dos seis padrões únicos de três itens

Padrã o	Combinação de itens	Lift máx.	Conf. máx.	Leitura
P1	Um a dois créditos ativos + idade de 60 anos ou mais + taxa de rejeição prévia até 25%	1,11	40%	Interessante
P2	Um a dois créditos ativos + crédito muito alto + separado, viúvo ou não informado	1,10	48%	Novidade preliminar
P3	Crédito médio + renda alta + solteiro	1,10	27%	Interessante

Padrão	Combinação de itens	Lift máx.	Conf. máx.	Leitura
P4	Idade entre 30 e 39 anos + renda muito alta + taxa de rejeição prévia até 25%	1,07	26%	Interessante
P5	Crédito médio + com carro + solteiro	0,99	25%	Sem associação positiva relevante
P6	Idade entre 21 e 29 anos + taxa de rejeição prévia até 25% + casado ou em união civil	0,98	71%	Sem associação positiva relevante

Fonte: reagrupamento das 36 regras de três itens por união antecedente $\cup$ consequente. Todos os seis padrões possuem suporte de 1% (100 transações).

6.3 Leitura conjunta de suporte, confiança e Lift


A comparação entre confiança e frequência marginal do consequente torna os resultados mais intuitivos. Quando a confiança é apenas um pouco maior que a frequência do consequente na amostra, o Lift fica ligeiramente acima de 1. Quando a confiança é menor que a frequência basal, o Lift fica abaixo de 1, mesmo que a confiança pareça numericamente alta.

Tabela 22 — Confiança observada versus frequência basal do consequente

Regra	Descrição	Conf.	Base do consequente	Δ p.p.	Lift
R1	Idade de 60 anos ou mais + um a dois créditos ativos → taxa de rejeição prévia até 25%	17%	15,27%	+1,73 p.p.	1,11
R3	Crédito muito alto + separado, viúvo ou não informado → um a dois créditos ativos	48%	43,46%	+4,54 p.p.	1,10
R4	Renda alta + solteiro → crédito médio	27%	24,45%	+2,55 p.p.	1,10
R9	Idade entre 30 e 39 anos + taxa de rejeição prévia até 25% → renda muito alta	26%	23,94%	+2,06 p.p.	1,07
R13	Com carro + solteiro → crédito médio	24%	24,45%	-0,45 p.p.	0,99
R15	Idade entre 21 e 29 anos + taxa de rejeição prévia até 25% → casado ou em união civil	71%	73,04%	-2,04 p.p.	0,98

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

Figura 6 — Confiança e Lift das vinte regras, com classificação interpretativa



Fonte: elaboração própria a partir dos resultados auditados do Trabalho 4.

Exemplo pedagógico — a regra R15 possui confiança de 71%, mas seu consequente — casado ou em união civil — já ocorre em 73,04% da amostra. Por isso o Lift é 0,98: a confiança alta não representa associação positiva, e sim a alta frequência marginal do consequente.

7 O QUE FOI NOVIDADE - E O QUE NÃO FOI

7.1 Critério de novidade

Neste relatório, “novidade” não significa simplesmente possuir o maior Lift. Uma regra foi considerada novidade apenas quando combina dimensões diferentes, não é consequência direta da construção das variáveis, apresenta associação positiva, não é somente a direção inversa de uma regra já interpretada e possui uma leitura plausível que não emerge de forma imediata das frequências marginais. Mesmo assim, o termo é usado como “novidade preliminar”, porque o suporte é de apenas 1% e o maior Lift observado é 1,11.

7.2 Novidade preliminar

O padrão classificado como novidade preliminar combina crédito muito alto, situação familiar separada/viúva/não informada e um a dois créditos ativos. A direção mais informativa é: “crédito muito alto + separado/viúvo/não informado → um a dois créditos ativos”. Essa regra possui suporte de 1%, confiança de 48% e Lift de 1,10.

A interpretação fica mais clara quando comparada à frequência basal: um a dois créditos ativos ocorre em 43,46% de toda a amostra. Entre os clientes que satisfazem o antecedente da regra, essa proporção sobe para 48%, diferença de aproximadamente 4,54 pontos percentuais. O Lift de 1,10 expressa exatamente esse aumento relativo modesto. Portanto, a regra é interessante como hipótese porque cruza porte de crédito, situação familiar e histórico ativo, mas não sustenta uma afirmação forte sobre o comportamento de clientes.

Por que é apenas preliminar — o suporte de 1% corresponde a 100 clientes; o Lift de 1,10 indica associação positiva discreta, e a categoria familiar agrega separado, viúvo e um único registro não informado. A regra deve ser confirmada em amostra maior antes de qualquer interpretação externa.

7.3 Padrões interessantes

Três padrões foram tratados como interessantes, mas não como novidades. O primeiro associa idade de 60 anos ou mais, um a dois créditos ativos e rejeição prévia até 25%; seu maior Lift é 1,11. O segundo combina renda alta, situação solteira e crédito médio, com Lift máximo de 1,10. O terceiro reúne idade de 30 a 39 anos, renda muito alta e rejeição prévia até 25%, com Lift máximo de 1,07. Todos atravessam dimensões distintas, mas a magnitude da associação continua pequena.

Tabela 23 — Padrões interessantes e direção de maior Lift

Padrão	Direção de maior Lift	Conf.	Lift	Sup.
Um a dois créditos ativos + idade de 60 anos ou mais + taxa de rejeição prévia até 25%	Idade de 60 anos ou mais + um a dois créditos ativos → taxa de rejeição prévia até 25%	17%	1,11	1,0%
Crédito médio + renda alta + solteiro	Renda alta + solteiro → crédito médio	27%	1,10	1,0%
Idade entre 30 e 39 anos + renda muito alta + taxa de rejeição prévia até 25%	Idade entre 30 e 39 anos + taxa de rejeição prévia até 25% → renda muito alta	26%	1,07	1,0%

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

7.4 Regras óbvias, inversões e independência

A classificação “óbvia” no arquivo original reúne duas situações distintas. A primeira é redundância direcional: uma mesma combinação de três itens pode aparecer em várias regras, alterando apenas quais itens ficam no antecedente ou no consequente. Essas regras não constituem novas descobertas porque descrevem o mesmo itemset. A segunda situação é ausência de associação positiva relevante, caracterizada por Lift próximo ou abaixo de 1.

Dois padrões ilustram esse segundo caso. “Com carro + solteiro + crédito médio” apresenta maior Lift de 0,99, praticamente independência. “21–29 anos + rejeição prévia até 25% + casado/união civil” tem maior Lift de 0,98; apesar de uma de suas direções possuir confiança de 71%, a frequência basal de casado/união civil é 73,04%, de modo que a regra não representa ganho positivo.

7.5 Síntese interpretativa

Tabela 24 — O que deve e o que não deve ser apresentado como descoberta

Classificação	Padrão/regra	Evidência	Conclusão
Novidade preliminar	Crédito muito alto + separado/viúvo/não informado → 1–2 créditos ativos	Lift 1,10; confiança 48%; +4,54 p.p. sobre a frequência basal.	Hipótese nova, porém fraca e apoiada em 100 registros.
Interessante	60+ + 1–2 créditos ativos + rejeição ≤25%	Maior Lift 1,11.	Padrão positivo discreto; merece investigação, não decisão.
Interessante	Renda alta + solteiro → crédito médio	Lift 1,10; confiança 27% contra basal de 24,45%.	Pequeno ganho de associação.
Interessante	30–39 + rejeição ≤25% → renda muito alta	Lift 1,07; confiança 26% contra basal de 23,94%.	Associação positiva fraca.

Classificação	Padrão/regra	Evidência	Conclusão
Não é descoberta	Com carro + solteiro + crédito médio	Maior Lift 0,99.	Praticamente independente.
Não é descoberta	21–29 + rejeição $\leq 25\%$ + casado/união civil	Maior Lift 0,98; uma direção tem 71% de confiança.	A confiança alta é explicada pela frequência basal de 73,04% do consequente.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

8 DISCUSSÃO

8.1 Implicações analíticas e comerciais

As associações podem ser usadas para formular perguntas de investigação, não para executar decisões automáticas. O padrão de crédito muito alto com situação familiar específica e um a dois créditos ativos, por exemplo, pode motivar análise complementar sobre composição do portfólio e trajetória de crédito. O padrão de renda alta e solteiro associado a crédito médio pode orientar uma exploração descritiva de produtos contratados. Em ambos os casos, o Lift próximo de 1 indica que qualquer ação operacional exigiria validação adicional em base maior e análise econômica externa.

A mineração também produz resultados úteis quando não encontra associação. Os padrões com carro/solteiro/crédito médio e jovem/rejeição/casado mostram que combinações aparentemente intuitivas não ganham suporte relativo frente às frequências marginais. Esse tipo de “resultado negativo” evita narrativas exageradas e demonstra por que métricas de associação devem ser interpretadas de forma conjunta.

8.2 Efeito da discretização e dos parâmetros

O resultado do Apriori é sensível à forma como variáveis contínuas são transformadas em itens e ao suporte mínimo adotado. Quartis de crédito e renda produziram faixas com volumes próximos, enquanto filhos, estado familiar e rejeição mantiveram categorias naturalmente desbalanceadas. Alterar os cortes mudaria as frequências marginais e, consequentemente, suporte, confiança e Lift. Por isso, as faixas são parte do modelo analítico e foram documentadas como decisão metodológica, não como detalhe de implementação.

A busca de suporte também evidenciou uma tensão entre frequência e quantidade de regras. Suportes maiores reduziram o universo de itemsets e não atingiram a meta de trinta regras de três itens. O suporte de 1% ampliou o espaço a 5.119 itemsets e viabilizou 36 regras de três itens, mas ao custo de trabalhar com padrões de apenas 100 transações. Esse compromisso precisa ser considerado ao avaliar a robustez das conclusões.

8.3 Robustez e generalização

Os resultados são reproduzíveis dentro da amostra e dos artefatos preservados, mas não devem ser generalizados automaticamente para os 307.511 registros da base original. A amostra de 10.000 linhas foi reaproveitada por continuidade metodológica com o Trabalho 3 e por viabilidade computacional; ainda assim, a estabilidade das regras deveria ser testada na

base completa ou em múltiplas amostras independentes antes de qualquer interpretação de população.

8.4 Recomendações para validação futura

Uma continuação natural do trabalho seria testar se os seis padrões identificados permanecem estáveis quando a população analisada ou as escolhas de discretização mudam. O objetivo dessa validação não seria aumentar artificialmente o Lift, mas verificar se as associações aparecem de forma consistente fora da configuração específica usada nesta entrega.

Tabela 25 — Validações recomendadas para trabalhos futuros

Teste	Procedimento	O que verificar
Base completa	Executar a mesma discretização nos 307.511 registros e repetir o Apriori.	Avaliar se suporte, confiança e Lift permanecem próximos aos observados na amostra.
Reamostragem	Repetir a análise em várias amostras independentes ou por bootstrap.	Medir estabilidade dos seis padrões e reduzir dependência de uma única amostra.
Sensibilidade das faixas	Alterar moderadamente os limites de discretização e repetir o ranking.	Identificar padrões robustos a pequenas mudanças nos cortes.
Sensibilidade do suporte	Comparar suportes próximos de 1% e métricas mínimas alternativas.	Verificar se o Top 20 muda drasticamente com pequenas alterações de parâmetro.
Validação externa	Confrontar padrões com contexto de negócio e dados de períodos distintos.	Separar coocorrências circunstanciais de associações potencialmente recorrentes.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

9 LIMITAÇÕES, ÉTICA E USO RESPONSÁVEL

9.1 Limitações

- Amostra de 10.000 registros: suficiente para o exercício, mas menor que a base original de 307.511 clientes.
- Discretização: reduz granularidade e introduz dependência dos limites escolhidos.
- Suporte de 1%: cada padrão final é sustentado por 100 transações, o que exige cautela.
- Lift moderado: o maior valor observado é 1,11; a maioria das diferenças em relação à frequência basal é de poucos pontos percentuais.
- Regras direcionais: as 36 regras de três itens derivam de apenas seis itemsets únicos; não representam 36 fenômenos independentes.
- WEKA 3.8.7: não há filtro nativo para total de três itens, exigindo execução exploratória separada e filtragem auditável.
- Categoria familiar agrupada: separado, viúvo e um caso não informado foram reunidos por frequência, o que reduz especificidade interpretativa.

9.2 Ética, LGPD e governança

As dimensões utilizadas incluem informações financeiras e familiares. Regras de associação não devem ser convertidas diretamente em critérios de aprovação, recusa, precificação ou priorização de clientes. Associação não implica causalidade, e uma regra agregada não autoriza inferências individuais.

Qualquer aplicação real exigiria base legal adequada, minimização de dados, governança, avaliação de vieses, monitoramento de impacto e supervisão humana, além de análise específica das obrigações previstas na LGPD. O presente trabalho tem finalidade acadêmica e exploratória; não constitui avaliação jurídica nem sistema de decisão de crédito.

10 CONCLUSÃO

O Trabalho 4 cumpriu a cadeia completa de preparação, discretização, representação transacional, mineração, fechamento e interpretação de regras de associação Apriori. Oito dimensões conceituais foram convertidas em 27 itens binários sobre 10.000 transações, com tratamento específico para o requisito `treatZeroAsMissing=true`. A execução real foi realizada no WEKA 3.8.7, preservando a saída obrigatória de 30 regras e os 5.119 itemsets gerados.

A busca de `lowerBoundMinSupport` mostrou que o requisito de pelo menos trinta regras de exatamente três itens não era alcançado pela configuração padrão de confiança. A solução metodologicamente transparente foi manter a execução obrigatória $N=30$ e, separadamente, utilizar uma execução exploratória com $N=2000$, Lift e suporte de 1%. Essa execução retornou 1.504 regras, das quais 36 tinham exatamente três itens. Após a construção do conjunto fechado, todas as 36 permaneceram elegíveis e as vinte melhores foram ordenadas por Lift.

A reanálise dos resultados permite uma conclusão mais precisa que a versão anterior do relatório: as 36 regras de três itens representam somente seis padrões únicos de coocorrência. Quatro desses padrões apresentam associação positiva discreta e dois estão próximos da independência ou em associação negativa. O maior Lift é 1,11; portanto, nenhuma descoberta deve ser tratada como forte.

A única novidade classificada como preliminar combina crédito muito alto, situação familiar separada/viúva/não informada e um a dois créditos ativos. Na direção mais informativa, a confiança é 48%, contra frequência basal de 43,46% para um a dois créditos ativos, com Lift 1,10 e suporte de 1%. O resultado merece investigação por cruzar dimensões distintas, mas o ganho absoluto de 4,54 pontos percentuais e o suporte de apenas 100 registros impedem qualquer conclusão operacional.

Os demais padrões positivos apresentam Lifts entre 1,07 e 1,11 e devem ser interpretados como hipóteses descritivas. Em contraste, a regra com 71% de confiança para casado/união civil evidencia a limitação da confiança isolada: o consequente já ocorre em 73,04% da amostra e o Lift é 0,98. Em síntese, o trabalho produz hipóteses rastreáveis para investigação posterior, não critérios para decisão automatizada de crédito.

REFERÊNCIAS

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules. Proceedings of the 20th International Conference on Very Large Data Bases (VLDB), 1994.

HAN, J.; KAMBER, M.; PEI, J. Data Mining: Concepts and Techniques. 4. ed. Morgan Kaufmann, 2023.

WEKA. Waikato Environment for Knowledge Analysis. Versão 3.8.7. Documentação e ajuda da instalação utilizada no trabalho.

UNIVERSIDADE FEDERAL DE UBERLÂNDIA. Trabalho Prático de Ciência de Dados - Regras de Associação. Enunciado da disciplina, 2026.

APÊNDICE A - MAPA DAS DISCRETIZAÇÕES

Este apêndice reúne, em uma única visão técnica, as 27 categorias discretizadas. Os limites foram aplicados antes da codificação binária e foram validados contra as frequências finais.

Tabela 26 — Mapa completo das 27 categorias discretizadas

Atributo	Categoria	Regra	Critério	n	%	Zero semântico
AMT_CREDIT	Crédito baixo	AMT_CREDIT <= 270000	P25	2.555	25,55%	Não
AMT_CREDIT	Crédito médio	270000 < AMT_CREDIT <= 512721	P25 a P50	2.445	24,45%	Não
AMT_CREDIT	Crédito alto	512721 < AMT_CREDIT <= 810000	P50 a P75	2.518	25,18%	Não
AMT_CREDIT	Crédito muito alto	AMT_CREDIT > 810000	Acima de P75	2.482	24,82%	Não
AMT_INCOME_TOTAL	Renda baixa	AMT_INCOME_TOTAL <= 112500	P25	3.279	32,79%	Não
AMT_INCOME_TOTAL	Renda média	112500 < AMT_INCOME_TOTAL <= 148500	P25 a P50	1.739	17,39%	Não
AMT_INCOME_TOTAL	Renda alta	148500 < AMT_INCOME_TOTAL <= 202500	P50 a P75	2.588	25,88%	Não
AMT_INCOME_TOTAL	Renda muito alta	AMT_INCOME_TOTAL > 202500	Acima de P75	2.394	23,94%	Não
AGE_YEARS	Idade entre 21 e 29 anos	21 <= AGE_YEARS <= 29	Semântico	1.218	12,18%	Não
AGE_YEARS	Idade entre 30 e 39 anos	29 < AGE_YEARS <= 39	Semântico	2.660	26,60%	Não
AGE_YEARS	Idade entre 40 e 49 anos	39 < AGE_YEARS <= 49	Semântico	2.526	25,26%	Não
AGE_YEARS	Idade entre 50 e 59 anos	49 < AGE_YEARS <= 59	Semântico	2.178	21,78%	Não
AGE_YEARS	Idade de 60 anos ou mais	AGE_YEARS > 59	Semântico	1.418	14,18%	Não
CNT_CHILDREN	Sem filhos	CNT_CHILDREN = 0	Zero semântico	6.961	69,61%	Sim
CNT_CHILDREN	Um filho	CNT_CHILDREN = 1	Semântico	2.005	20,05%	Não

Atributo	Categoria	Regra	Critério	n	%	Zero semântico
CNT_CHILDREN	Dois ou mais filhos	CNT_CHILDREN >= 2	Frequência	1.034	10,34%	Não
FLAG_OWN_CAR_COD	Sem carro	codigo 0	Dicionário do Trabalho 1	6.605	66,05%	Sim
FLAG_OWN_CAR_COD	Com carro	codigo 1	Dicionário do Trabalho 1	3.395	33,95%	Não
NAME_FAMILY_STATUS_CODE	Casado ou em união civil	codigos 1 ou 2	Semântica e frequência	7.304	73,04%	Não
NAME_FAMILY_STATUS_CODE	Solteiro	codigo 4	Dicionário do Trabalho 1	1.498	14,98%	Não
NAME_FAMILY_STATUS_CODE	Separado, viúvo ou não informado	codigos 0, 3 ou 5	Frequência	1.198	11,98%	Sim
SER_CREDITOS_ATIVOS	Sem créditos ativos	SER_CREDITOS_ATIVOS = 0	Zero semântico	2.956	29,56%	Sim
SER_CREDITOS_ATIVOS	Um a dois créditos ativos	1 <= SER_CREDITOS_ATIVOS <= 2	Frequência	4.346	43,46%	Não
SER_CREDITOS_ATIVOS	Três ou mais créditos ativos	SER_CREDITOS_ATIVOS >= 3	Frequência	2.698	26,98%	Não
PREV_TAXA_REJEICAO	Sem rejeição prévia	PREV_TAXA_REJEICAO = 0	Zero semântico	6.771	67,71%	Sim
PREV_TAXA_REJEICAO	Taxa de rejeição prévia até 25%	0 < PREV_TAXA_REJEICAO <= 0.25	P25 entre valores positivos	1.527	15,27%	Não
PREV_TAXA_REJEICAO	Taxa de rejeição prévia acima de 25%	PREV_TAXA_REJEICAO > 0.25	P50 aproximado entre valores positivos	1.702	17,02%	Não

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

APÊNDICE B - HISTÓRICO COMPLETO DOS TESTES DE SUPORTE

A tabela abaixo preserva as 32 tentativas registradas na busca experimental. O objetivo é tornar visível o caminho até a configuração com suporte de 1%, em vez de apresentar apenas o teste bem-sucedido.

Tabela 27 — Histórico integral da busca de lowerBoundMinSupport

Teste	Suporte	N	Métrica	Min. métrica	Regras	3 itens	Itemsets	Tempo WEKA (s)
param_autorizado_conviction_c100_s005	0,050	30	conviction (3)	1,00	20	0	652	4,335
param_autorizado_leverage_c001_s005	0,050	30	leverage (2)	0,01	0	0	652	2,408
param_autorizado_lift_c000_s001_exploratorio_n2000	0,010	2000	lift (1)	0,00	1504	36	5119	5,263
param_autorizado_lift_c000_s001_n30	0,010	30	lift (1)	0,00	30	0	5119	5,293
param_autorizado_lift_c000_s002_exploratorio_n500	0,020	500	lift (1)	0,00	152	24	2358	2,876
param_autorizado_lift_c010_s001_exploratorio_n500	0,010	500	lift (1)	0,10	500	0	5119	9,833
param_autorizado_lift_c010_s002	0,020	30	lift (1)	0,10	30	6	2358	4,360
param_autorizado_lift_c010_s002_exploratorio_n500	0,020	500	lift (1)	0,10	152	24	2358	3,844
param_autorizado_lift_c010_s005	0,050	30	lift (1)	0,10	30	0	652	2,323
param_autorizado_lift_c030_s005	0,050	30	lift (1)	0,30	30	0	652	2,232
param_autorizado_lift_c050_s005	0,050	30	lift (1)	0,50	30	0	652	2,019

Teste	Suporte	N	Métrica	Min. métrica	Regras	3 itens	Itemsets	Tempo WEKA (s)
suporte_001_exploratorio_n1000	0,010	1000	confidence (0)	0,90	361	2	5119	4,370
suporte_001_exploratorio_n200	0,010	200	confidence (0)	0,90	200	1	5119	4,778
suporte_002_exploratorio_n200	0,020	200	confidence (0)	0,90	107	13	2358	4,288
suporte_003	0,030	30	confidence (0)	0,90	9	4	652	2,887
suporte_0039_delta_001	0,039	30	confidence (0)	0,90	9	4	652	1,678
suporte_004	0,040	30	confidence (0)	0,90	9	4	652	0,679
suporte_004_delta_001	0,040	30	confidence (0)	0,90	9	4	652	1,966
suporte_005	0,050	30	confidence (0)	0,90	9	4	652	0,477
suporte_0075	0,075	30	confidence (0)	0,90	9	4	340	0,507
suporte_010	0,100	30	confidence (0)	0,90	7	4	221	0,416
suporte_015	0,150	30	confidence (0)	0,90	1	0	104	0,383
suporte_020	0,200	30	confidence (0)	0,90	1	0	54	0,388
suporte_025	0,250	30	confidence (0)	0,90	0	0	30	0,285
suporte_030	0,300	30	confidence (0)	0,90	0	0	20	0,232
suporte_040	0,400	30	confidence (0)	0,90	0	0	11	0,267
suporte_050	0,500	30	confidence (0)	0,90	0	0	0	0,291
suporte_exato_004	0,040	30	confidence (0)	0,90	0	0	909	1,964
suporte_janela_002_001	0,010	30	confidence (0)	0,90	30	0	5119	4,672
suporte_janela_003_002	0,020	30	confidence (0)	0,90	30	4	2358	2,383
suporte_janela_004_003	0,030	30	confidence (0)	0,90	9	2	1402	2,007
suporte_janela_005_004	0,040	30	confidence (0)	0,90	9	2	909	2,049

Fonte: resumo_testes_suporte.csv preservado no repositório.

APÊNDICE C - TOP 20 COMPLETO E INTERPRETAÇÃO TÉCNICA

As regras são reproduzidas em linguagem legível, mantendo as métricas reais e a classificação registrada. As direções inversas foram preservadas porque fazem parte do Top 20, mas não são contadas como descobertas independentes.

Tabela 28 — Top 20 com justificativa interpretativa

Regra	Descrição	Sup.	Conf.	Lift	Classe	Justificativa
R1	Idade de 60 anos ou mais + um a dois créditos ativos → taxa de rejeição prévia até 25%	1,0%	17%	1,11	Interessante	Combina estágio de vida e histórico de crédito com rejeição prévia; o Lift 1,11 indica associação positiva discreta, mas o suporte de 1% pede cautela.
R2	Taxa de rejeição prévia até 25% → idade de 60 anos ou mais + um a dois créditos ativos	1,0%	7%	1,11	Óbvia	É a direção inversa do mesmo itemset da regra 1 e tem confiança de 7%; não acrescenta evidência independente ao padrão.
R3	Crédito muito alto + separado, viúvo ou não informado → um a dois créditos ativos	1,0%	48%	1,10	Novidade	Crédito muito alto e situação familiar separada/viúva/não informada se associam a um a dois créditos ativos (Lift 1,10; confiança 48%). São dimensões diferentes e não há relação construída por fórmula, embora seja uma novidade preliminar pelo suporte de 1%.
R4	Renda alta + solteiro → crédito médio	1,0%	27%	1,10	Interessante	Renda alta e situação solteira associam-se a crédito médio, unindo renda, perfil familiar e crédito. O Lift 1,10 é positivo, porém modesto e observado em 1% das transações.
R5	Um a dois créditos ativos + taxa de rejeição prévia até 25% → idade de 60 anos ou mais	1,0%	16%	1,10	Óbvia	Reorganiza os mesmos três itens da regra 1; a inversão de antecedente e consequente não constitui uma descoberta adicional.
R6	Idade de 60 anos ou mais → um a dois créditos ativos + taxa de rejeição prévia até 25%	1,0%	7%	1,10	Óbvia	Outra direção do itemset da regra 1, com confiança de 7%; descreve o mesmo coocorrimento sem novo poder descritivo.

Regra	Descrição	Sup.	Conf.	Lift	Classe	Justificativa
R7	Crédito médio → renda alta + solteiro	1,0%	4%	1,10	Óbvvia	É a direção inversa do itemset da regra 4 e possui confiança de 4%, insuficiente para tratá-la como descoberta separada.
R8	Um a dois créditos ativos → crédito muito alto + separado, viúvo ou não informado	1,0%	2%	1,10	Óbvvia	É a direção inversa da regra 3 e tem confiança de 2%; não amplia a interpretação da novidade preliminar já registrada.
R9	Idade entre 30 e 39 anos + taxa de rejeição prévia até 25% → renda muito alta	1,0%	26%	1,07	Interessante	Idade de 30 a 39 anos com rejeição prévia moderada associa-se a renda muito alta. A associação entre trajetória de crédito e renda é plausível, mas o Lift 1,07 e o suporte de 1% são fracos.
R10	Renda muito alta → idade entre 30 e 39 anos + taxa de rejeição prévia até 25%	1,0%	4%	1,07	Óbvvia	Inverte a regra 9 e apresenta confiança de 4%; é uma reformulação de itemset, não uma evidência nova.
R11	Crédito médio + renda alta → solteiro	1,0%	16%	1,05	Óbvvia	É uma das direções do mesmo itemset renda alta, crédito médio e situação solteira já representado pela regra 4; não deve ser contado como nova descoberta.
R12	Solteiro → crédito médio + renda alta	1,0%	7%	1,05	Óbvvia	Inverte a regra 11, com confiança de 7%, e apenas reexpressa a mesma coocorrência.
R13	Com carro + solteiro → crédito médio	1,0%	24%	0,99	Óbvvia	Lift de 0,99 é praticamente independência; posse de carro e situação solteira não oferecem evidência útil de associação com crédito médio.
R14	Crédito médio → com carro + solteiro	1,0%	4%	0,99	Óbvvia	É a inversão da regra 13, também próxima da independência e com confiança de 4%.
R15	Idade entre 21 e 29 anos + taxa de rejeição prévia até 25% → casado ou em união civil	1,0%	71%	0,98	Óbvvia	A confiança de 71% acompanha a alta frequência de casado/união civil na amostra; o Lift 0,98 não sustenta associação positiva específica.

Regra	Descrição	Sup.	Conf.	Lift	Classe	Justificativa
R16	Casado ou em união civil → idade entre 21 e 29 anos + taxa de rejeição prévia até 25%	1,0%	1%	0,98	Óbvvia	É a direção inversa da regra 15, com confiança de 1%, e não supera a explicação pela frequência predominante de casado/união civil.
R17	Crédito médio + solteiro → renda alta	1,0%	25%	0,97	Óbvvia	Reorganiza os mesmos itens das regras 4 e 11; Lift 0,97 não indica associação positiva relevante.
R18	Renda alta → crédito médio + solteiro	1,0%	4%	0,97	Óbvvia	Inverte a regra 17, com confiança de 4% e Lift 0,97; não há descoberta adicional.
R19	Renda muito alta + idade entre 30 e 39 anos → taxa de rejeição prévia até 25%	1,0%	15%	0,95	Óbvvia	Lift 0,95 indica associação negativa leve, praticamente independente, entre renda muito alta, idade de 30 a 39 anos e rejeição prévia moderada.
R20	Taxa de rejeição prévia até 25% → renda muito alta + idade entre 30 e 39 anos	1,0%	7%	0,95	Óbvvia	É a direção inversa da regra 19 e mantém Lift 0,95 e confiança de 7%; não configura padrão novo.

Fonte: elaboração própria a partir dos artefatos auditados do Trabalho 4.

APÊNDICE D - RASTREABILIDADE DOS ARTEFATOS

Tabela 29 — Artefatos centrais e rastreabilidade

Arquivo	Finalidade	Bytes	SHA-256 (prefixo)
data/discretizadas/base_apriori_discretizada.csv	Base semântica final (8 dimensões)	1.327.822	a7444cbdadd08918...
data/preparadas/base_apriori_binaria.csv	Base técnica utilizada pelo Apriori (27 itens)	540.905	7e42f2c9aaaa81a7...
resultados/apriori/execucao_final/ resultado_apriori_final.txt	Saída real da execução N=30	735.902	efc9cadf7bf35c14...
resultados/apriori/execucao_final/ configuracao_apriori_final.json	Configuração real do WEKA	1.942	c9fec233f2f5a6bf...
resultados/itemsets/itemsets_apriori.csv	5.119 itemsets extraídos	772.960	22f7232a7fc39404...
resultados/conjunto_fechado/itemsets_fechados.csv	5.072 itemsets fechados	1.064.727	e3aa56c4232057a6...
resultados/regras/top20_regras_lift.csv	Top 20 por Lift	2.762	a7451ae8e1361293...
resultados/regras/analise_top20_regras.csv	Classificação e justificativa das 20 regras	5.737	13b769051991e638...

Fonte: arquivos locais correspondentes aos artefatos do repositório auditado; snapshot GitHub: commit 596af4742a5711268ae414afbd04577309fb7ee7.

Snapshot do repositório utilizado para a reanálise: ygor-marangoni/entrega-pre-processamento-ciencia-de-dados, branch main, commit 596af4742a5711268ae414afbd04577309fb7ee7, consultado em 07/08/2026. Os resultados científicos do relatório permanecem vinculados aos arquivos listados acima.